PPO, 보행로봇은 어떻게 스스로 걷기를 배우나 ?

W2 · Sim2Real Walking Robot Challenge

한 문장

PPO = 잘한 행동은 조금 더 하고 , 못한 행동은 조금 줄이되 , 한 번에 너무 크게 바꾸지 않는 학습법

오늘 목표

수식 암기보다 Observation → Action → Reward → Update 의 흐름 이해

프로젝트 연결

Baseline PPO 를 만든 뒤 Reward / DR / Actuator Modeling 을 비교

12 살에게 설명하면

“로봇에게 걷기 점수를 주면서 조금씩 연습시키는 것”

- 로봇이 다리를 움직여 본다 .
- 앞으로 잘 가면 + 점수 , 넘어지면 - 점수 .
- 점수가 높았던 행동은 다음에 조금 더 해본다 .
- 하지만 행동을 한 번에 확 바꾸지 않는다 .
- 이 과정을 수천 . 수만 번 반복하면 보행이 점점 좋아진다 .

강화학습의 네 가지 재료

Environment
MuJoCo 속 로봇과 바닥

Observation
관절각 , 속도 , 몸의 기울기

Action
각 관절에 줄 명령

Reward
잘 걷는 정도를 나타내는 점수

한 번의 학습 루프



상태를 본다 → 행동을 고른다 → 로봇이 움직인다 → 점수를 받는다 → 정책을 조금 수정

Policy 는 무엇인가 ?

“이 상황에서 어떤 행동을 할까 ?” 를 정하는 로봇의 행동 규칙

Observation

몸이 오른쪽으로 기울고 있다
관절 3 번이 많이 접혀 있다
앞으로 가라는 명령이 있다

정책 $\pi(a|s) \rightarrow$

Policy → Action

왼쪽 다리에 힘을 더 준다
오른쪽 다리를 앞으로 낸다
몸의 균형을 되돌린다

왜 “ Proximal” 인가 ?

좋아졌다고 해서 정책을 너무 멀리 점프시키지 않는다

너무 작은 변화
학습이 느리지만 비교적 안정적

적당한 변화
좋았던 행동을 반영하면서 기존 능력도 보존

너무 큰 변화
한 번의 업데이트로 이미 잘하던 행동까지 무너질 수 있음

PPO 의 핵심 직관 : “ 더 좋아지되 , 한 번에 너무 멀리 가지 말자 .”

PPO 의 clipping 을 직관적으로

- 이전 정책보다 어떤 행동의 확률을 너무 크게 올리거나 내리지 않도록 제한한다 .
- 좋은 경험을 활용하지만 “이번 한 번의 경험” 에 과도하게 끌려가지 않게 한다 .
- 그래서 로봇 보행처럼 연속적인 제어 문제에서 안정적으로 쓰이는 경우가 많다 .

새 정책 ≈ 이전 정책 + “ 적당한” 개선

보행에서는 Reward 가 사실상 “선생님” 이다

Forward
앞으로 가면 +

Stay Upright
넘어지지 않으면 +

Energy
에너지를 너무 쓰면 -

Smoothness
너무 흔들리면 -

- Reward 를 잘못 설계하면 “점수는 높은데 이상하게 걷는” 로봇이 나올 수 있다 .

우리 프로젝트의 Baseline A

A. Baseline

기본 PPO
기본 reward
randomization 없음

→ 비교의 기준점

왜 먼저 필요한가 ?

B/C/D 가 좋아졌는지 말하려면
먼저 “아무것도 추가하지 않은 PPO” 가
얼마나 걷는지 알아야 한다 .

A/B/C/D Controlled Comparison

A. Baseline
기본 PPO

B. Reward
보상 설계 변경

C. Domain Randomization
질량 · 마찰 ·delay 등을 랜덤화

D. Actuator Modeling
실제 servo 특성을 simulation 에 반영

PPO 를 볼 때 무엇을 기록할까 ?

- Reward curve: 학습하면서 점수가 실제로 오르는가 ?
- Success rate: 여러 번 실행했을 때 몇 번 성공하는가 ?
- Body roll/pitch: 몸이 얼마나 흔들리는가 ?
- Energy / torque: 걷기 위해 얼마나 무리하는가 ?
- Failure mode: Fall, No Progress, Oscillation, Foot Slip 등은 언제 생기는가 ?

오늘 논문 읽기와 PPO 를 연결하는 질문

- 이 논문은 PPO 의 무엇을 바꿨나 ? Reward? Observation? Action? Environment?
- 왜 그 변화가 보행을 더 안정적으로 만들었나 ?
- 그 결과가 고가 로봇이 아니라 저가 servo 에서도 유지될까 ?
- Simulation 에서 좋아진 것이 실제 로봇에서도 좋아질까 ?
- 우리가 재현할 수 있는 최소 실험은 무엇인가 ?

Take-away

PPO = “ 좋은 행동을 조금 더 하되 , 한 번에 너무 크게 바꾸지 않는” 강화학습 방법

오늘
PPO 의 흐름 이해

이번 주
Seed Paper → RQ → baseline 재현

다음 단계
A/B/C/D 실험으로 확장